

Report IUM 2024-2025

Stoica Stefanut Cosmin

Solution

L'analisi è stata sviluppata all'interno di un notebook Jupyter (analisi.ipynb) utilizzando Python e alcune librerie dedicate all'analisi e alla visualizzazione dei dati. In particolare sono stati usati pandas e numpy per la gestione dei dati tabellari, matplotlib per i grafici e geopandas per la creazione delle mappe. Tutte le dipendenze necessarie sono elencate nel file requirements.txt, in modo da rendere l'ambiente facilmente ricreabile.

La struttura del progetto è semplice e ordinata: la cartella data/ contiene i file CSV esterni utilizzati per l'analisi (non versionati nel repository), la cartella src/ contiene moduli python utilizzati per la soluzione, mentre la cartella assets/ ospita le risorse di supporto già fornite, in particolare lo shapefile di Natural Earth usato per i confini dei paesi.

Il notebook segue un flusso logico e facilmente leggibile: dopo il caricamento dei dataset vengono eseguite operazioni di pulizia dei dati, sistemazione delle colonne e unione delle tabelle quando necessario. Successivamente vengono calcolate le metriche di interesse e prodotti sia grafici tradizionali sia visualizzazioni geografiche.

Per la parte geografica sono state utilizzate librerie GIS (Geographic Information System) in modo da evitare la gestione manuale di coordinate, proiezioni e geometrie. Questo approccio semplifica molto la creazione delle mappe, anche se comporta l'uso di librerie piuttosto pesanti che possono rendere l'installazione meno immediata.

Il notebook è organizzato in sezioni ben definite:

- Setup iniziale: import delle librerie e definizione dei percorsi dei file presenti in data/ e assets/.
- Caricamento dei dati: lettura dei CSV tramite pandas e primi controlli sulle colonne principali.
- Pulizia dei dati: rinomina delle colonne, sistemazione dei formati (ad esempio date o categorie), gestione dei valori mancanti e rimozione di duplicati.
- Unione dei dataset: join tra tabelle per ottenere informazioni più complete sui record.
- Calcolo delle metriche: conteggi, medie, distribuzioni e preparazione dei dati per le visualizzazioni.

- Visualizzazioni: grafici con matplotlib e mappe geografiche con geopandas, utilizzando lo shapefile presente in assets/.

Issues

Il lavoro si basa su dataset CSV forniti esternamente e questo ha introdotto alcune difficoltà.

La prima riguarda la pulizia dei dati, poiché i CSV non sono versionati e possono presentare formati diversi o valori mancanti. È stato quindi necessario intervenire manualmente per sistemare colonne e tipi di dato.

Un'altra difficoltà è stata l'allineamento dei dati con le mappe. Per poter creare mappe corrette, i nomi dei paesi presenti nei CSV dovevano corrispondere a quelli dello shapefile Natural Earth. In alcuni casi è stato necessario rinominare o mappare manualmente questi valori.

Requirements

Il codice è scritto in modo ordinato e coerente, con nomi chiari per variabili e funzioni e una formattazione uniforme. Il notebook è diviso in celle appoggiate a moduli esterni in maniera logica, seguendo il flusso dell'analisi, e questo rende il lavoro facile da leggere e da seguire. Nei punti più delicati, come il caricamento dei dati, sono presenti controlli di base per gestire possibili errori.

Pandas è stato utilizzato in modo corretto, sfruttando operazioni come merge, groupby e aggregazioni per combinare i dataset e ottenere risultati significativi. I dati vengono caricati correttamente dai file CSV e le informazioni analizzate risultano pertinenti e interessanti rispetto agli obiettivi del progetto.

La fase di pulizia dei dati è stata effettivamente svolta ed è risultata necessaria per sistemare formati non coerenti, valori mancanti e duplicati. Questo ha permesso di ottenere risultati corretti. L'approccio è adatto a dataset di dimensioni medio-grandi, anche se su volumi molto elevati sarebbero necessarie soluzioni più strutturate.

L'analisi dei dati è semplice ma efficace e permette di ricavare informazioni utili. I risultati sono corretti e comprensibili. Le visualizzazioni, sia tramite grafici sia tramite mappe geografiche, sono adeguate e aiutano a interpretare i dati.

Il codice è commentato dove necessario e il report spiega in modo chiaro le scelte fatte.

Limitations

La soluzione presenta alcune limitazioni.

I dati utilizzati non sono inclusi nel repository e devono essere forniti manualmente. Eventuali cambiamenti nel formato dei CSV richiedono modifiche al notebook.

Dal punto di vista delle prestazioni, il notebook è pensato per analisi esplorative su dataset di dimensioni medio-piccole. Per volumi di dati più grandi o per analisi ripetute nel tempo sarebbe preferibile una soluzione più strutturata.

Bibliography

1. https://github.com/nvkelso/natural-earth-vector/blob/master/110m_cultural/
2. <https://maddmaths.simai.eu/divulgazione/rubriche/la-lente-matematica/entropia-di-shannon/>